Primeiras simulações em grupo: relatório consolidado

MAE0552 Teoria da Informação

Universidade de São Paulo, Instituto de Matemática e Estatística

São Paulo, outubro de 2026

Integrantes do grupo

- Yasmim da Silva Sobrinho
- Iohanna Elblaus Souza
- Lucas Kousuke Matsunaga
- Bruno Rocha Levi
- Enzo Takeshi Ikeda

Introdução

Este relatório reúne as quatro atividades de simulação propostas em `propostas/1_Simulacoes.pdf`. Cada tópico parte de um problema concreto, define um modelo probabilístico, gera dados segundo esse modelo, estima quantidades de teoria da informação "na mão" a partir dos dados e compara as estimativas com os valores teóricos.

Tópico	Problema	Resultado teórico testado
1	Teste rápido de dengue ao longo de vários dias	Entropia, informação mútua, regra da cadeia, teste G
2	Telefone sem fio, classificador e colapso de modelo	Desigualdade de processamento de dados
3	Apostas em um campeonato de futebol	AEP, compressão e critério de Kelly
4	Link de rádio Terra-Marte transmitindo uma imagem	Capacidade do canal e teorema de Shannon

Todos os tópicos usam as mesmas funções de entropia, entropia conjunta e condicional, informação mútua e divergência de Kullback-Leibler, escritas a partir das definições em `utils/info_theory.py`, sem funções prontas de biblioteca para a quantidade de interesse. Cada tópico tem um notebook com um passo do roteiro por seção, com semente fixa: todos os números deste relatório saem da execução desses notebooks e as figuras são as que eles gravam em `topicoN_.../figuras/`. A unidade de informação é sempre o bit (log na base 2).

Tabelas e figuras são numeradas por tópico (Tabela 3.2 é a segunda tabela do Tópico 3).

---

1. Entropia, informação mútua e teste de independência

1.1 Objetivo

Decidir se um teste rápido de dengue carrega informação real sobre o estado de saúde do paciente e quantos bits, no mínimo, são necessários para transmitir o histórico de testes ao longo de vários dias.

1.2 Modelo

D é o estado de saúde (1 = infectado) e T o resultado do teste (1 = positivo). Foram escolhidos prevalência P(D=1) = 0,08, taxa de falso positivo P(T=1 | D=0) = 0,03 e taxa de falso negativo P(T=0 | D=1) = 0,12, o que dá a conjunta da Tabela 1.1.

Tabela 1.1. Distribuição conjunta p(d, t).

	T=0	**T=1**	**total**
D=0	0,8924	0,0276	0,9200
D=1	0,0096	0,0704	0,0800
total	0,9020	0,0980	1,0000

Os valores teóricos são H(D) = 0,4022, H(T) = 0,4626, H(D,T) = 0,6234, H(D|T) = 0,1607 e I(D;T) = 0,2414 bit.

Para a dimensão temporal (Passos 6 a 8), D segue uma cadeia de Markov de 2 estados com $P(D=0 \to 1) = a = 0{,}02$ e $P(D=1 \to 0) = b = 0{,}23$. A distribuição estacionária de uma cadeia de 2 estados é [b, a]/(a+b), então escolher $b = a(1 - \pi)/\pi$, com π a prevalência, faz a cadeia ter exatamente a prevalência do modelo acima em regime. Assim a extensão temporal descreve a mesma população dos Passos 1 a 5. A cadeia é iniciada na estacionária, não em um estado fixo.

1.3 Método

Geração de N pares (D, T) e estimativa das mesmas quantidades por contagem; varredura de N com 400 amostras independentes por valor de N; entropia cruzada e $D(p\|q)$ para um q(D) diferente do verdadeiro; dimensão temporal pela cadeia de Markov; teste G de independência, escrito como $G = 2N \ln 2 \cdot \hat{I}(D;T)$.

Nos Passos 7 e 8 as quantidades comparadas também são calculadas de forma exata. Como D é Markov e T depende apenas do D do mesmo dia, o par (D, T) é um modelo oculto de Markov, e $p(t_1 \ldots t_n)$ sai do algoritmo forward somando sobre os caminhos de D. As estimativas por contagem são então conferidas contra esse valor exato, e não contra outra estimativa.

1.4 Resultados

Passos 1 a 3: teoria contra estimativa. Observar T reduz a incerteza sobre D de 0,4022 para 0,1607 bit, ou seja, em 60%. Uma amostra de N = 2000 pares reproduz bem as marginais (prevalência 0,0835 contra 0,08, positividade 0,0935 contra 0,0980), e as estimativas por contagem ficam próximas da teoria (Tabela 1.2).

Tabela 1.2. Estimativas por contagem com N = 2000.

quantidade	estimado	teórico	erro relativo (%)
H(D)	0,4144	0,4022	3,04
H(T)	0,4480	0,4626	3,15
H(D,T)	0,6215	0,6234	0,30
H(D|T)	0,1735	0,1607	7,92
I(D;T)	0,2409	0,2414	0,22

O IC bootstrap de 95% para I(D;T) é [0,2004, 0,2820] e cobre o valor teórico. A concordância em I(D;T) é melhor que nas entropias que a compõem porque os erros de H(T) e H(D|T) apontam para o mesmo lado e se cancelam na diferença.

Passo 4: convergência com N. Com 400 amostras independentes por N, a média de $\hat{I}(D;T)$ converge para o valor teórico e a faixa entre os percentis 10 e 90 encolhe (Tabela 1.3, Figura 1.1). A partir de N = 500 o erro da média fica abaixo de 1%.

Tabela 1.3. $\hat{I}(D;T)$ médio em 400 amostras por N.

N	Î médio	erro relativo (%)	faixa 10% a 90%
20	0,2639	9,3	[0,0000, 0,6098]
50	0,2700	11,8	[0,1084, 0,4465]
100	0,2467	2,2	[0,1266, 0,3725]
500	0,2401	0,6	[0,1927, 0,2878]
2000	0,2412	0,1	[0,2154, 0,2670]
10000	0,2418	0,1	[0,2305, 0,2532]

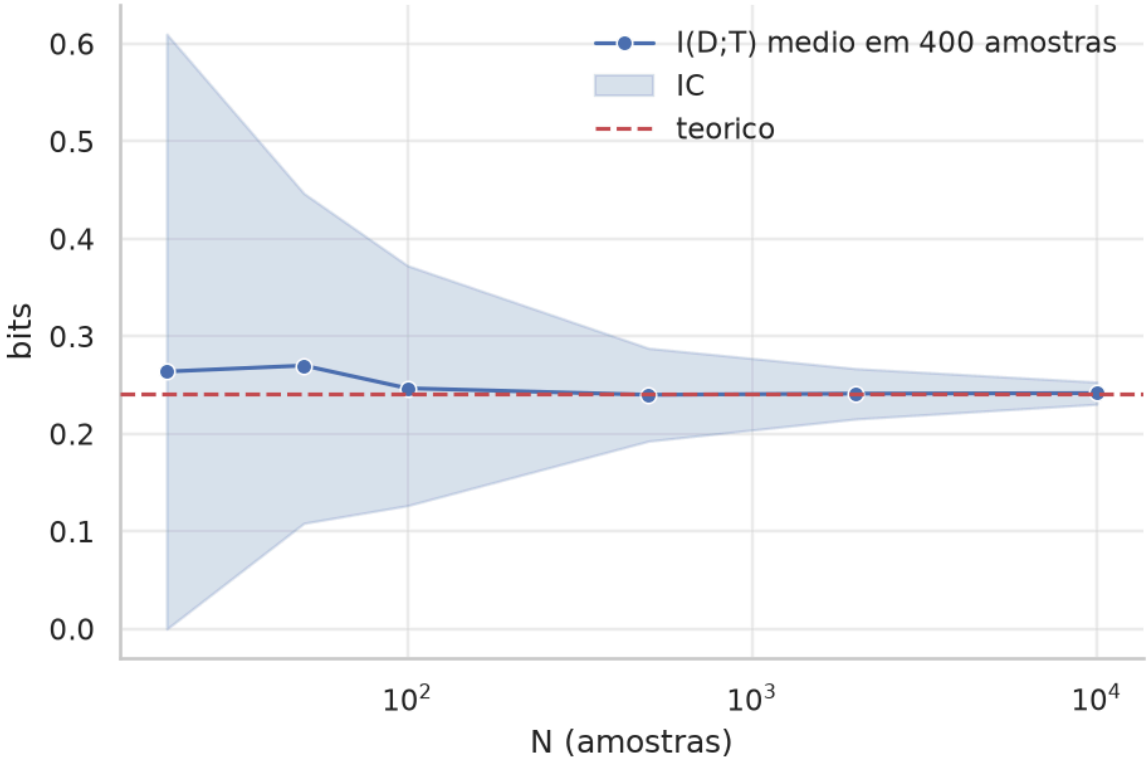


Figura 1.1. Erro de Î(D;T) em função de N.

Passo 5: modelo errado. Para q(D) = [0,85, 0,15], H(p,q) = 0,4347 bit contra H(p) = 0,4022, e a diferença de 0,0325 bit coincide com D(p‖q) = 0,0325. Codificar D com o modelo errado custa 8% a mais de bits, e esse excesso é exatamente a divergência de Kullback-Leibler.

Passo 6: série temporal. A cadeia calibrada tem matriz de transição [[0,98, 0,02], [0,23, 0,77]] e estacionária [0,92, 0,08]. A série simulada mostra longos trechos em D=0 interrompidos por episódios curtos de infecção, com T acompanhando D e errando ocasionalmente (Figura 1.2).

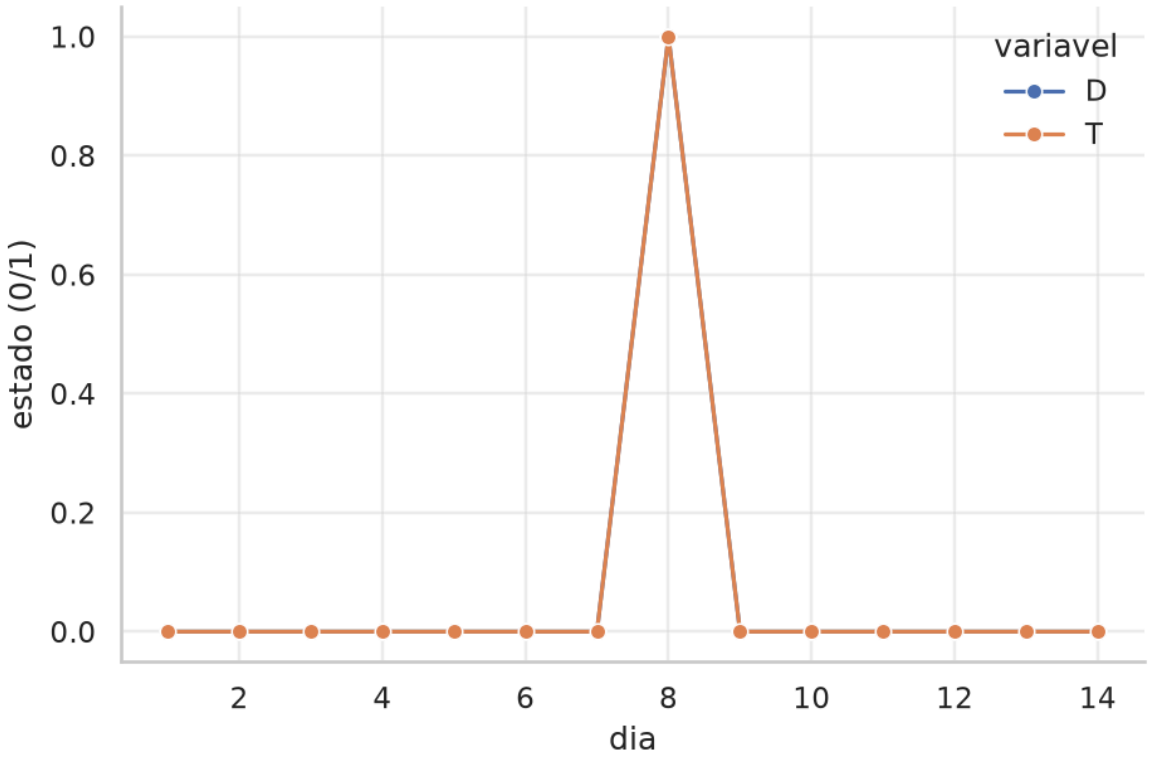


Figura 1.2. Série de D e T ao longo dos dias.

Passo 7: regra da cadeia. Para n = 8 dias e 20000 pacientes, as estimativas por contagem ficam a menos de 1,3% dos valores exatos (Tabela 1.4).

Tabela 1.4. Entropia da sequência de testes, n = 8.

quantidade	estimado	exato	erro relativo (%)
$H(T_1 \ldots T_8)$	2,9391	2,9773	1,28
soma $H(T_i \mid T_{i-1})$	3,0290	3,0571	0,92
$8 \cdot H(T_1)$	3,6843	3,7010	0,45

O ponto conceitual está na relação entre as duas primeiras linhas. T sozinho não é uma cadeia de Markov: quem é Markov é D, e T é a observação ruidosa dele. A regra da cadeia condiciona em todo o passado, $H(T_1 \ldots T_n) = \Sigma\, H(T_i \mid T_1 \ldots T_{i-1})$; condicionar apenas em T_{i-1} é uma aproximação de ordem 1 e, portanto, um limite superior. A folga entre as duas é de 0,0797 bit, 2,7% de $H(T_1 \ldots T_8)$. É pequena, mas estrutural, e não ruído de estimação: aparece igual no cálculo exato (Figura 1.3).

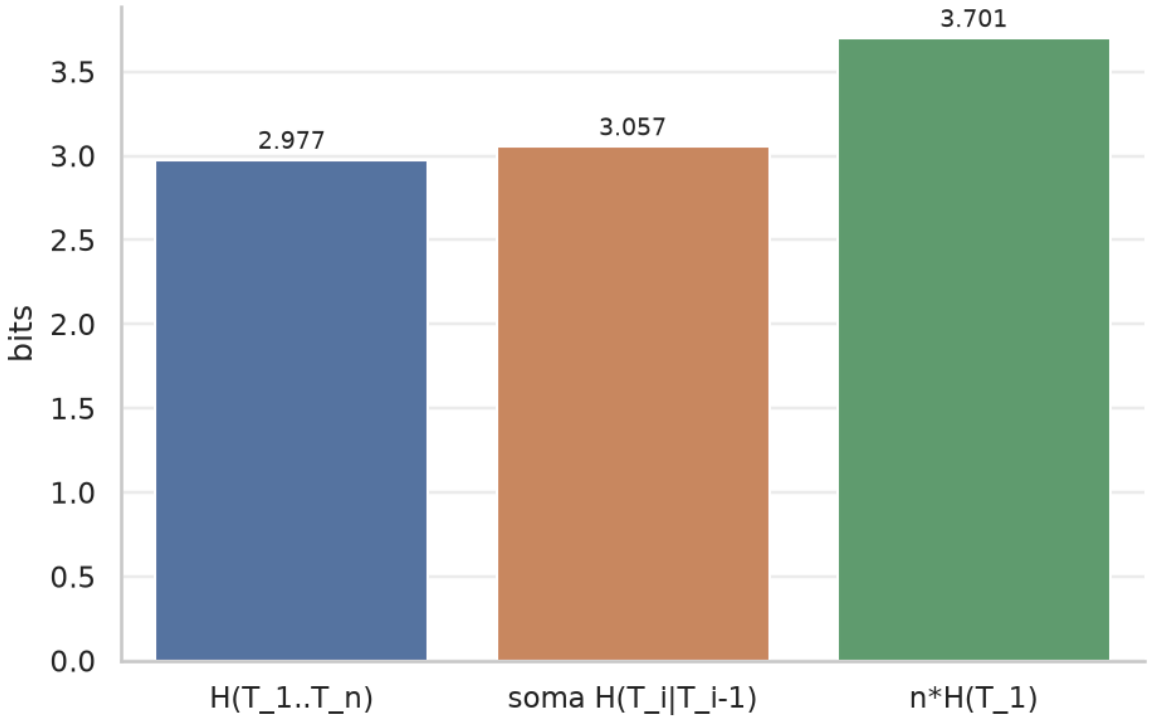


Figura 1.3. $H(T_1 \ldots T_n)$, soma das condicionais de ordem 1 e $n \cdot H(T_1)$.

Passo 8: economia de bits. Transmitir os 8 dias como amostras independentes custa 3,7010 bits por paciente. Usando o dia anterior como contexto o custo cai para 3,0571 bits (economia de 0,6439 bit, 17,4%), e usando todo o passado cai para 2,9773 bits (economia de 0,7236 bit, 19,6%). A memória de um único dia já captura 89% de toda a economia disponível (Figura 1.4). Como a cadeia está em regime, T_1 tem a mesma distribuição de qualquer outro dia, e a comparação mede dependência temporal, não efeito da condição inicial.

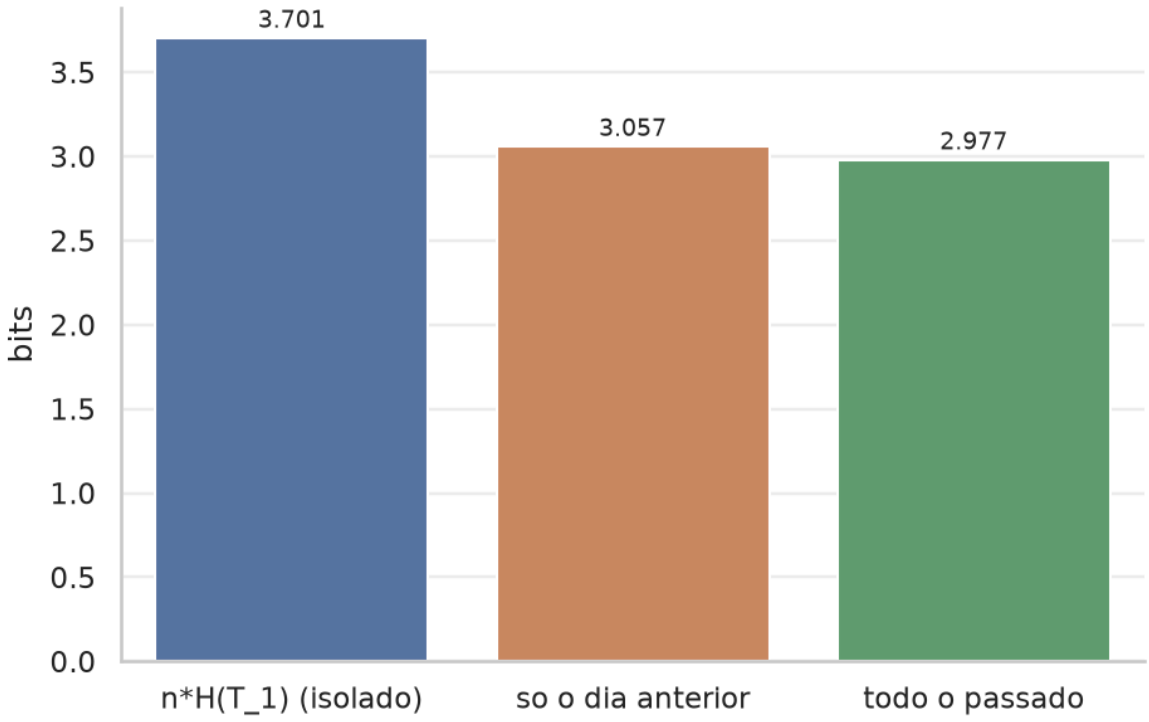


Figura 1.4. Economia de bits ao usar a dependência temporal.

Passo 9: teste G. O teste rejeita a independência nos dois casos (Tabela 1.5). Os 20000 pares $T_2 \times T_1$ são um por paciente, portanto independentes entre si.

Tabela 1.5. Teste G de independência.

teste	N	Î (bits)	G	g.l.	p-valor
D × T	2000	0,2409	667,95	1	$2{,}8\times10^{-147}$
$T_2 \times T_1$	20000	0,0919	2547,46	1	$< 10^{-300}$

Passo 10: poder e nível do teste. Com N = 300 e R = 1000 repetições por cenário, a taxa de rejeição acompanha a força da dependência e, sob independência verdadeira, fica no nível nominal (Tabela 1.6, Figura 1.5). O erro de Monte Carlo da taxa sob H_0 é $\sqrt{(0{,}05\cdot0{,}95/1000)} = 0{,}0069$, então 0,049 está dentro do esperado: o teste não é anticonservador nessas condições. Na dependência fraca (I = 0,0137 bit) ele rejeita em 65% das repetições; o poder é limitado, mas a decisão está correta na maioria delas.

Tabela 1.6. Taxa de rejeição a α = 0,05.

cenário	I(D;T) teórico	taxa de rejeição
dependência forte	0,2414	1,000
dependência fraca	0,0137	0,654
independência real	0,0000	0,049

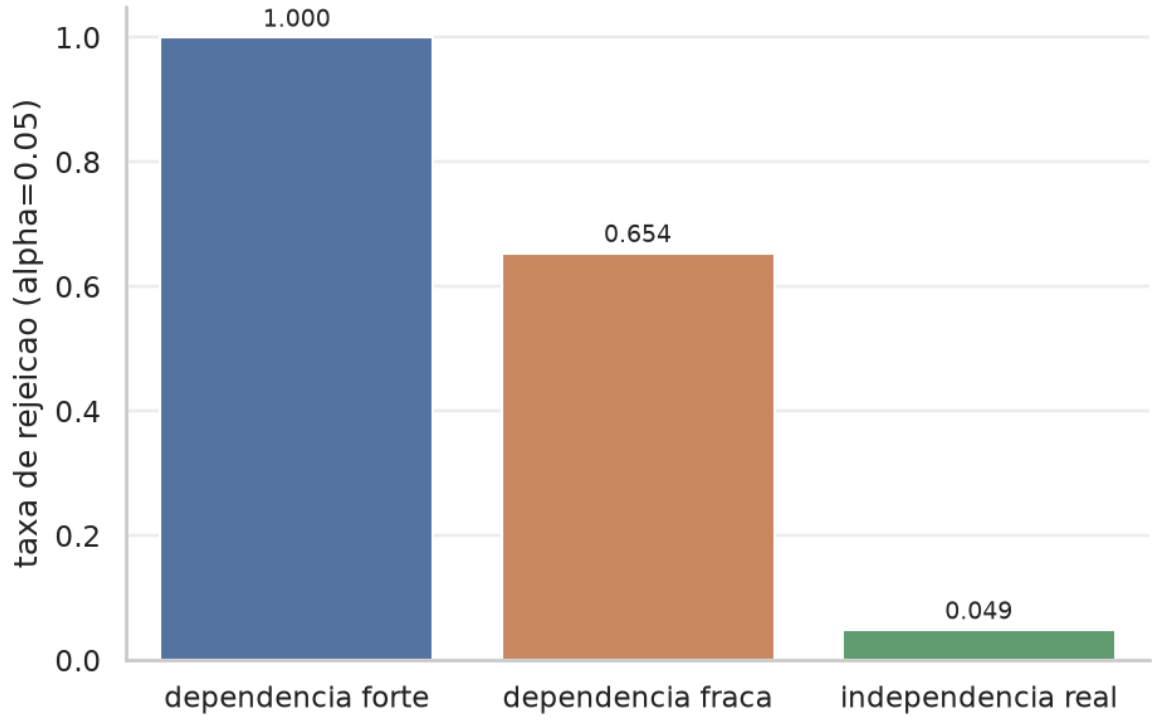


Figura 1.5. Taxa de rejeição do teste G por cenário.

1.5 Discussão

Viés de amostra finita. A informação mútua estimada por contagem é enviesada para cima, e o viés cresce com o tamanho do alfabeto e cai com N; por isso o Passo 4 usa a média de 400 amostras por N, e não uma amostra só. Em N = 20 aparece um segundo efeito que o viés sozinho não explica: 21% das amostras não contêm nenhum infectado (a probabilidade teórica é $0{,}92^{20} = 19\%$), e nelas a tabela de contingência tem uma linha vazia e $\hat{I}$ sai exatamente zero. A distribuição de $\hat{I}$ em N = 20 é bimodal, o que faz a média em N = 20 ficar abaixo da média em N = 50, ao contrário do que se esperaria de um viés puro. O percentil 10 igual a zero na Tabela 1.3 é a marca dessas amostras.

Contagens esperadas pequenas. No Passo 10 a menor contagem esperada é $N \cdot P(D=1) \cdot P(T=1|D=1) \approx 300 \cdot 0{,}08 \cdot 0{,}88 \approx 21$, acima do mínimo prático de 5 para confiar na aproximação qui-quadrado. Com amostras bem menores a taxa de erro tipo I deixaria de ser confiável.

Independência das observações no teste G. O teste pressupõe N observações independentes, e G cresce linearmente com N. Empilhar os 7 pares consecutivos (T_1,T_2), (T_2,T_3), … de cada paciente daria 7M "observações" que se sobrepõem duas a duas e vêm da mesma trajetória. A estatística sairia inflada por pseudorreplicação, por um fator da ordem de 7, sem que nenhuma informação nova tivesse entrado. Por isso o Passo 9 usa um único par por paciente.

Economia de bits e condição inicial. A comparação entre o custo condicional e $n \cdot H(T_1)$ só mede dependência temporal se a cadeia estiver em regime. Iniciada fora da estacionária, $H(T_1)$ reflete a condição inicial: partindo de um estado uniforme a "economia" chegaria a 2,49 bits, e partindo da prevalência do Passo 1 com uma cadeia não calibrada ela chegaria a ser negativa. Nenhum dos dois números diria algo sobre dependência temporal.

1.6 Conclusão

O teste rápido carrega informação real sobre o estado de saúde: $I(D;T) = 0{,}2414$ bit, 60% da incerteza sobre D, confirmado pelo teste G com p-valor da ordem de 10^{-147}. O histórico de testes tem dependência temporal explorável, mas o ganho é modesto: cerca de 20% dos bits, quase todo ele já disponível olhando apenas o dia anterior. As estimativas convergem para a teoria, com dois efeitos distintos em N pequeno (o viés para cima da informação mútua e as amostras sem nenhum infectado), e o teste G ganha poder conforme a dependência real fica mais forte, mantendo o erro tipo I no nível nominal quando D e T são de fato independentes.

---

2. Desigualdade de processamento de dados e cadeias de Markov

2.1 Objetivo

Comprovar por simulação que nenhuma etapa de processamento cria informação nova sobre a entrada: $I(X;Y_1) \geq I(X;Y_2) \geq \ldots$ ao longo de uma cadeia de Markov $X \to Y_1 \to Y_2 \to \ldots$.

2.2 Modelo

- **Fonte.** X é um bit com P(X) = [0,5, 0,5], logo H(X) = 1 bit, o teto de $I(X;Y_j)$ em toda a cadeia.
- **Telefone sem fio.** K = 5 elos, cada um um canal binário simétrico (BSC) com p = 0,10 no cenário base e p ∈ {0,02, 0,05, 0,10, 0,20} na varredura do Passo 6.
- **Cadeia inspirada em IA (Passo 7).** Duas classes equiprováveis; "imagem" de 8 coordenadas, gaussiana com média ±s por classe, com s decaindo de 2,0 a 0,0 ao longo das coordenadas e ruído σ = 1,5; compressão pela média de blocos de 4 coordenadas (8 → 2); decisão pela média de classe mais próxima. As variáveis contínuas são projetadas na direção da diferença das médias e discretizadas em 10 classes por quantis para estimar as informações mútuas.
- **Colapso de modelo (Passo 8).** pmf real sobre 6 categorias, [0,05, 0,10, 0,15, 0,30, 0,25, 0,15]; 15 gerações; tamanho de amostra por geração ∈ {30, 100, 300}; 40 trajetórias independentes por tamanho.

O enunciado tem 9 passos e o notebook tem 8: os passos 7 e 8 do enunciado (montar a cadeia rótulo → imagem → representação → predição e calcular a informação entre o rótulo e cada estágio) estão juntos no Passo 7, porque a verificação da DPI reamostra os estágios em conjunto; o passo 9 do enunciado é o Passo 8.

2.3 Método

Propagação de N = 20000 mensagens por todos os estágios, guardando cada estágio e não só o último; estimativa de $I(X;Y_j)$ com IC bootstrap; varredura da intensidade do ruído; cadeia rótulo → imagem → representação → predição; gerações sucessivas medindo a distância até a distribuição real.

Duas decisões metodológicas merecem registro. A DPI afirma que a informação cai de um estágio para o seguinte, então o que precisa de intervalo de confiança é a queda, e não cada estágio isoladamente. A reamostragem tem de ser pareada nos mesmos índices, porque os dois estágios vêm das mesmas amostras e seus erros são correlacionados; comparar dois ICs que se sobrepõem não responde à pergunta. Além disso, no Passo 8 a trajetória de cada cadeia de gerações é aleatória e uma única trajetória não descreve o processo, por isso cada tamanho de amostra é repetido 40 vezes.

Como a composição de k BSCs de parâmetro p é um BSC de parâmetro $p_k = (1 - (1 - 2p)^k)/2$, o valor teórico de cada elo é $I(X;Y_k) = 1 - H_b(p_k)$, e as estimativas podem ser conferidas contra ele.

2.4 Resultados

Passos 1 a 3. Um bloco de exemplo X = [0,1,1,0,1] chega ao fim da cadeia como Y_5 = [0,1,1,1,0]: dois dos cinco bits foram invertidos em algum ponto. Com N = 20000 mensagens, as marginais empíricas de X e de todos os Y_j ficam entre 0,5026 e 0,5060: o canal degrada a informação sem mexer na marginal, o bit continua equiprovável e apenas deixa de estar ligado ao original.

Passos 4 e 5: degradação ao longo da cadeia. $I(X;Y_j)$ cai de 0,5255 bit em Y_1 para 0,0784 bit em Y_5, sempre abaixo do teto de 1 bit (Tabela 2.1, Figura 2.1).

Tabela 2.1. Informação mútua ao longo da cadeia (p = 0,10 por elo).

elo	estimado (bits)	IC 95%	teórico
$I(X;Y_1)$	0,5255	[0,5126, 0,5387]	0,5310
$I(X;Y_2)$	0,3071	[0,2960, 0,3198]	0,3199
$I(X;Y_3)$	0,1923	[0,1828, 0,2020]	0,1984
$I(X;Y_4)$	0,1248	[0,1169, 0,1327]	0,1247
$I(X;Y_5)$	0,0784	[0,0719, 0,0851]	0,0789

As diferenças sucessivas são −0,2184, −0,1148, −0,0675 e −0,0464 bit, todas negativas, e nenhum elo apresenta aumento significativo pelo critério dos ICs disjuntos. A queda desacelera, porque sobra cada vez menos informação para destruir. Quatro dos cinco ICs cobrem o valor teórico; o de Y_2 fica 0,0001 bit abaixo dele, o que é compatível com a cobertura nominal de 95%.

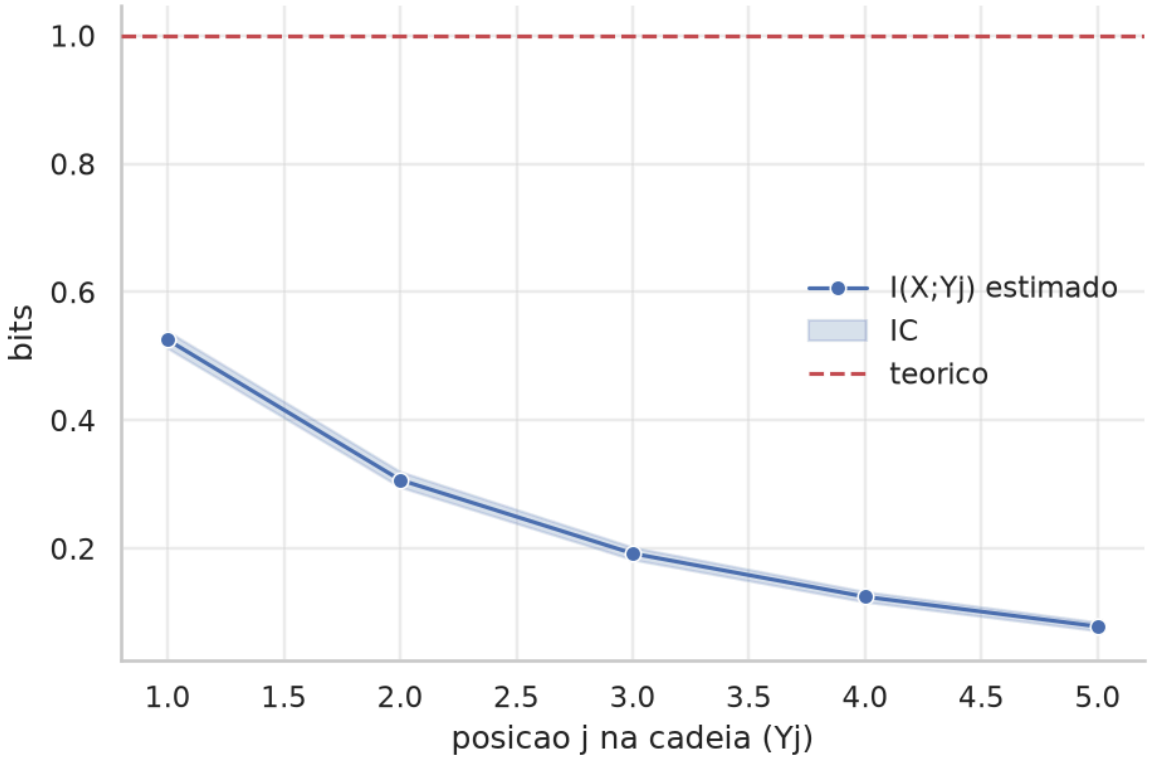


Figura 2.1. Degradação de $I(X;Y_j)$ ao longo da cadeia, com IC bootstrap.

Passo 6: intensidade do ruído. Quanto maior o ruído por elo, mais rápida a degradação (Tabela 2.2, Figura 2.2). Com p = 0,20, cinco elos reduzem a informação a 0,0055 bit e o bit final praticamente não guarda relação com o original; com p = 0,02 ainda restam 0,55 bit. A degradação é aproximadamente geométrica, porque o efeito do ruído se compõe elo a elo. As estimativas ficam a menos de 0,02 bit dos valores teóricos $1 - H_b(p_k)$ em todas as células.

Tabela 2.2. $I(X;Y_j)$ em bits para diferentes intensidades de ruído.

p por elo	Y_1	Y_2	Y_3	Y_4	Y_5
0,02	0,8447	0,7486	0,6721	0,5971	0,5456
0,05	0,7121	0,5395	0,4239	0,3350	0,2614
0,10	0,5377	0,3260	0,1985	0,1228	0,0787
0,20	0,2765	0,0982	0,0376	0,0135	0,0055

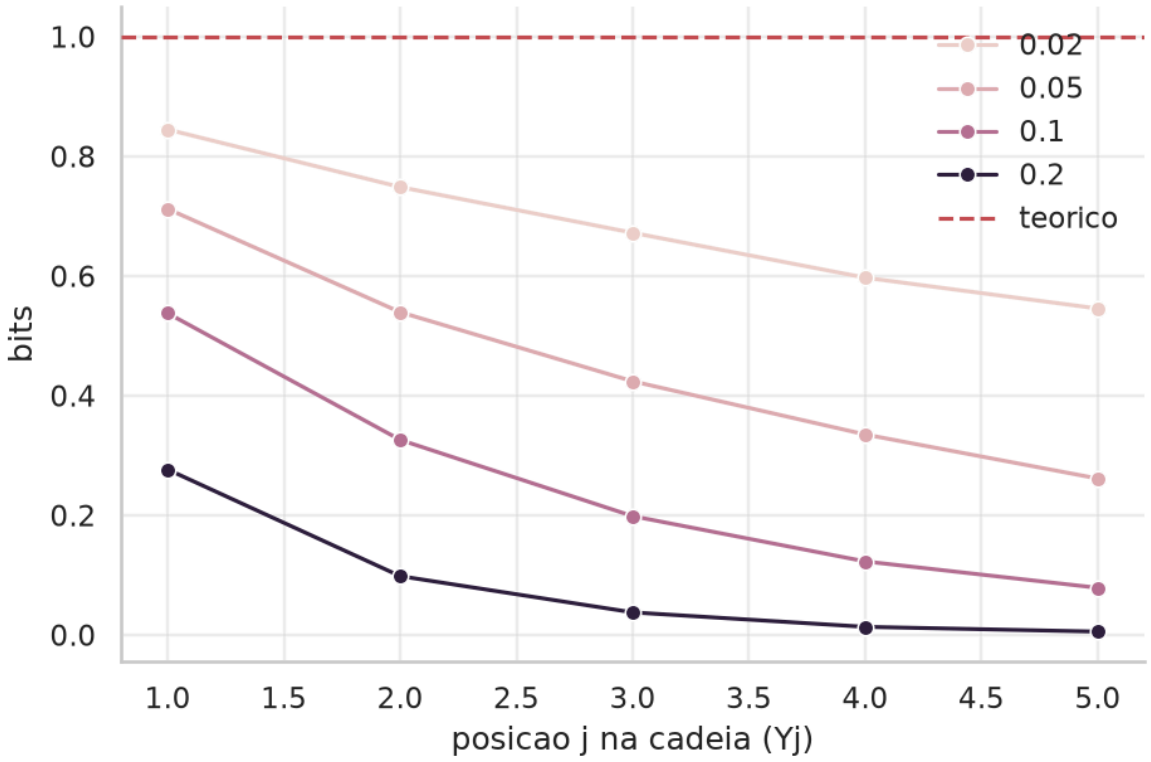


Figura 2.2. Degradação de $I(X;Y_j)$ para diferentes intensidades de ruído.

Passo 7: cadeia rótulo → imagem → representação → predição. Com N = 20000 rótulos, a informação sobre o rótulo cai a cada estágio (Tabela 2.3). O que comprova a DPI não é a ordem dos três números, e sim o IC das quedas entre estágios consecutivos, reamostradas de forma pareada (Tabela 2.4). Os dois intervalos são inteiramente positivos, então as duas quedas estão resolvidas pelos dados.

Tabela 2.3. Informação sobre o rótulo em cada estágio.

estágio	I(rótulo; estágio) (bits)	IC 95%
imagem completa	0,8920	[0,8846, 0,8998]
representação comprimida	0,8713	[0,8636, 0,8795]
predição final	0,8104	[0,7992, 0,8217]

Tabela 2.4. Queda de informação entre estágios consecutivos.

transição	queda (bits)	IC 95% da queda
imagem → representação	0,0207	[0,0158, 0,0261]
representação → predição	0,0609	[0,0555, 0,0672]

O classificador por distância às médias acerta 97,09% dos rótulos (o valor teórico é 97,00%). Ele perde 0,0609 bit de informação sobre o rótulo e ainda assim quase não erra, porque o que descarta é a informação sobre quão confiante estava, e não sobre qual classe era.

Passo 8: colapso de modelo. Em 15 gerações, cada uma estimada apenas a partir da amostra finita da geração anterior, a distância até a distribuição real cresce, e cresce mais rápido quanto menor a amostra por geração (Tabela 2.5, Figura 2.3).

Tabela 2.5. Estado das trajetórias na geração 15 (40 trajetórias por linha).

N por geração	trajetórias com categoria extinta	categorias vivas (mediana)	variação total até p_real (mediana)	D(p_real‖p_ger) finita (mediana)
30	100,0%	3 de 6	0,5167	nenhuma finita
100	77,5%	5 de 6	0,3100	0,2113
300	17,5%	6 de 6	0,1867	0,1895

Com 30 amostras por geração, todas as 40 trajetórias perderam pelo menos uma categoria, e a mediana é de metade do alfabeto extinta. A divergência não tem valor finito em nenhuma delas: não é que ela seja grande, é que o modelo passou a atribuir probabilidade zero a eventos que acontecem. Com 300 amostras por geração o colapso é bem mais lento, mas não desaparece.

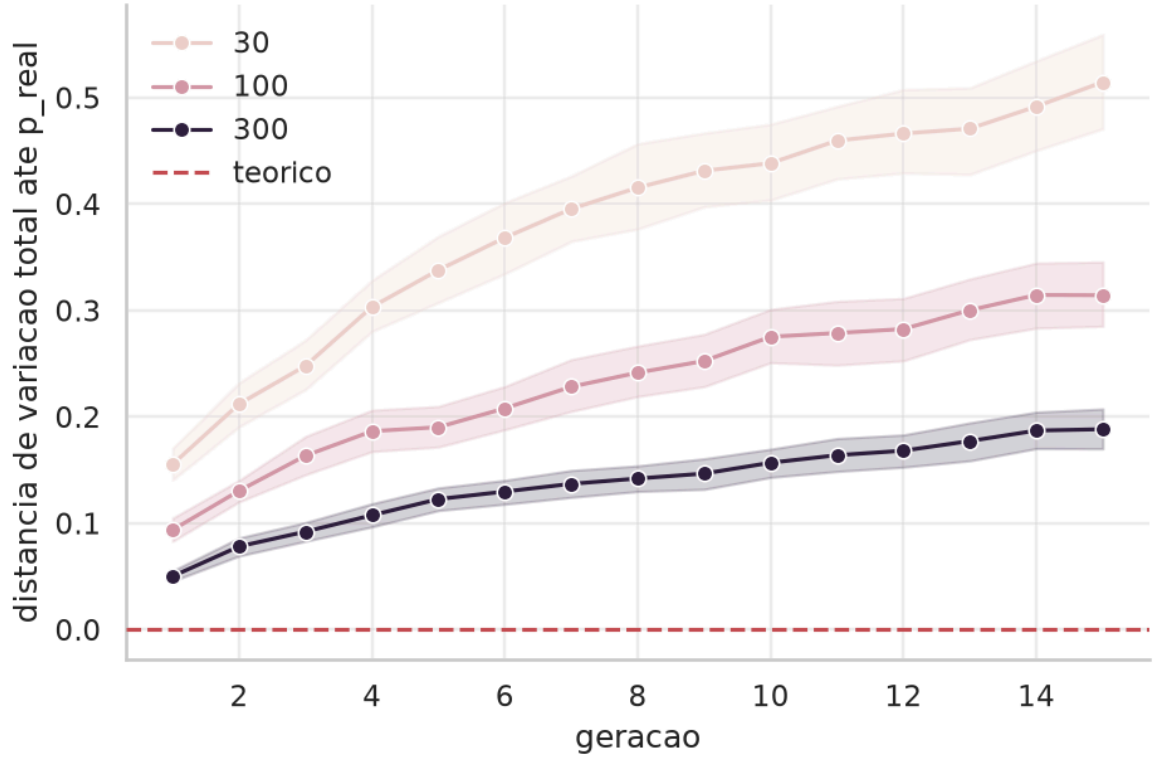


Figura 2.3. Distância até p_real ao longo das gerações.

2.5 Discussão

Solavancos para cima na curva. Um aumento aparente de $I(X;Y_j)$ é ruído de estimação, não violação da DPI. O critério para decidir isso sai dos próprios ICs, e não de uma tolerância escolhida à mão: um elo só sobe de verdade se o piso do seu IC ficar acima do teto do IC do elo anterior. Um limiar fixo, como "aceitar aumentos de até 0,01 bit", falharia nas duas direções: aceitaria como ruído um aumento real em um trecho de baixa variância e reprovaria como violação um solavanco de estimação em um trecho de alta.

De onde vem a queda na compressão. A projeção da imagem completa na direção da diferença das médias é estatística suficiente para o rótulo, porque a covariância é isotrópica; a média por blocos não é, porque o sinal varia dentro de cada bloco (de 2,0 a 0,8 no primeiro, de 0,4 a 0,0 no segundo). Medida em desvios-padrão do ruído, a meia distância entre as classes cai de 1,983 na imagem para 1,881 na representação. Com a mesma discretização em 10 classes nos dois estágios, a conta exata dá 0,8890 bit para a imagem e 0,8672 bit para a representação, uma queda de 0,0218 bit compatível com a estimada (0,0207). A discretização também custa informação (sem ela os valores seriam 0,9095 e 0,8866 bit), mas afeta os dois estágios quase igualmente; a queda medida é, portanto, efeito da compressão.

Tamanho de amostra na cadeia de IA. Uma queda de 0,021 bit é pequena. Com N = 2000 rótulos, o desvio-padrão dessa queda entre réplicas é da ordem de 0,009 bit, metade do efeito: a desigualdade não ficaria resolvida pelos dados, e uma realização qualquer poderia sair com o sinal invertido. Com N = 20000 o IC da queda é inteiramente positivo.

Extinção de categorias no colapso de modelo. Uma categoria que zera numa geração nunca mais volta, porque a amostragem seguinte não tem como sorteá-la. Isso é o próprio colapso, não um defeito da simulação. Mas $D(p_real \| p_ger)$ fica infinita no instante em que a primeira categoria morre, e a trajetória da divergência se perde dali em diante. Uma simulação com uma única trajetória e uma semente favorável reportaria uma divergência finita e não veria nada disso. Por isso o passo acompanha também a distância de variação total, que continua finita depois da extinção, e conta quantas categorias sobraram.

2.6 Conclusão

A simulação confirma a desigualdade de processamento de dados em três cenários distintos: canal ruidoso composto, cadeia rótulo → imagem → predição e colapso de modelo por gerações sucessivas. A informação mútua nunca cresce ao processar dados adiante, cai mais rápido quanto maior o ruído por elo, e a queda entre estágios só pode ser afirmada quando excede a incerteza da estimativa, o que exigiu reamostrar a diferença e não cada estágio. No colapso de modelo, uma cadeia de estimativas em amostra finita acumula divergência da distribuição real geração após geração mesmo sem nenhum viés introduzido de propósito, e o mecanismo dominante não é uma deriva suave: é a extinção irreversível de categorias, que depende fortemente de quantos exemplos cada geração vê.

---

3. Compressão de dados, AEP e critério de Kelly

3.1 Objetivo

Verificar se o logaritmo do patrimônio de um apostador, dividido pelo número de rodadas, se concentra em torno de um valor determinístico (AEP); comparar o crescimento das estratégias "tudo no favorito", uniforme e Kelly; medir quanto vale, em bits, uma informação lateral imperfeita; e quanto se perde ao apostar com crenças erradas.

3.2 Fundamentação

Se $X_1, \ldots, X_n$ são i.i.d. com distribuição p, a Lei dos Grandes Números aplicada a $-\log_2 p(X_i)$ dá $-(1/n) \log_2 p(X_1, \ldots, X_n) \to H(X)$. Quase toda a probabilidade fica no conjunto típico, com cerca de 2^(nH) sequências, e por isso cerca de nH bits bastam para descrever a fonte: a taxa mínima de compressão sem perdas é a entropia.

Com m resultados de probabilidades p_i, cotações o_i ("o_i para 1") e frações apostadas b_i ($\Sigma\, b_i = 1$), o patrimônio é multiplicado por $b(X_k) \cdot o(X_k)$ a cada rodada, e

$(1/n) \log_2 S_n \to W(b,p) = \Sigma\, p_i \log_2(b_i\, o_i)$.

A estratégia que maximiza W é b = p (Kelly), e vale $W(b,p) = W^* - D(p\|b)$, com $W^* = \Sigma\, p_i \log_2 o_i - H(p)$. Qualquer desvio de p custa exatamente D(p‖b) bits por rodada, e apostar zero num resultado possível leva a $W = -\infty$. Se o apostador observa uma informação lateral Y e aposta b(y) = p(x|y), o ganho de taxa é exatamente $\Delta W = I(X;Y)$ (Cover e Thomas, 2006, cap. 6).

Definindo $c = 1/\Sigma(1/o_i)$ e os preços implícitos $r_i = c/o_i$, tem-se $W^* = \log_2 c + D(p\|r)$. Se $\Sigma(1/o_i) > 1$ a casa embute uma margem ($\log_2 c < 0$), e o apostador só cresce se suas probabilidades se afastarem dos preços do mercado o bastante para que D(p‖r) supere essa margem.

3.3 Modelo e método

- **Mundo simulado.** Campeonato de futebol com três resultados por rodada (casa, empate, visitante), p = (0,5; 0,3; 0,2) e cotações o = (2; 3; 5).
- **Escala logarítmica.** O patrimônio é acumulado em $\log_2$ (soma dos ganhos por rodada), para evitar estouro numérico.
- **Vetorização.** 1000 temporadas de 200 rodadas simuladas de uma vez, como matriz, o que permite estimar distribuições e não apenas trajetórias isoladas.
- **Estratégias.** Tudo no favorito, b = (1, 0, 0); uniforme, b = (1/3, 1/3, 1/3); Kelly, b = p.
- **Informação lateral.** Uma dica Y com matriz p(y|x) da Tabela 3.1 é sorteada junto com X, e o apostador usa b(y) = p(x|y). A comparação com Kelly sem dica usa os mesmos sorteios de X (comparação pareada).
- **Crenças erradas.** Um apostador que acredita em q = (0,7; 0,2; 0,1) aposta b = q nas mesmas temporadas.
- **Cotações uniformes.** As mesmas temporadas reapostadas contra uma casa que paga $o_i = 3$ para todos os resultados.

Tabela 3.1. Matriz p(y|x) da dica usada como informação lateral.

resultado real \ dica	casa	empate	visitante
casa (p = 0,5)	0,70	0,20	0,10
empate (p = 0,3)	0,15	0,70	0,15
visitante (p = 0,2)	0,10	0,20	0,70

3.4 Resultados

Entropia da fonte e margem da casa. $H(p) = 1{,}4855$ bits, abaixo do máximo de $\log_2 3 = 1{,}5850$ bits para três símbolos. Uma longa sequência de resultados pode ser descrita com cerca de 1,49 bit por rodada em vez de 1,59. Um código de Huffman para p (comprimentos 1, 2 e 2) tem comprimento médio de 1,5 bit, apenas 0,0145 bit acima da entropia, de acordo com $H \le L < H + 1$.

Quanto às cotações, $\Sigma\, 1/o_i = 1{,}0333$: a casa embute uma margem de cerca de 3,3%. Os preços implícitos $r = (0{,}484;\ 0{,}323;\ 0{,}194)$ são muito próximos de p ($D(p\|r) = 0{,}0017$ bit), então $W^* = \log_2 c + D(p\|r) = -0{,}0473 + 0{,}0017 = -0{,}0456$ bit por aposta. Neste cenário nenhuma estratégia sem informação adicional tem crescimento positivo; o que se avalia é qual perde menos e como o crescimento se comporta.

Comparação entre as estratégias.

Tabela 3.2. Taxa de crescimento $(1/n)\log_2 S_n$ após 200 rodadas, em 1000 temporadas.

estratégia	taxa média (bits/aposta)	desvio-padrão	temporadas com $\log_2 S < -20$	W teórico
tudo no favorito	$-\infty$	não se aplica	100,0%	$-\infty$
uniforme	−0,1454	0,0352	89,1%	−0,1451
Kelly	−0,0457	0,0049	0,0%	−0,0456

"Tudo no favorito" quebra em todas as temporadas: basta um resultado diferente do favorito para o patrimônio zerar, e a chance de o favorito vencer 200 rodadas seguidas é $0{,}5^{200} \approx 6 \cdot 10^{-61}$. Ainda assim, o fator esperado por rodada dessa estratégia é $0{,}5 \times 2 = 1$: o patrimônio esperado não muda, mas é sustentado por eventos de probabilidade desprezível. É o exemplo clássico de como a esperança aritmética engana em processos multiplicativos, e de por que a escala logarítmica é a correta.

A estratégia uniforme fica em −0,1454 contra W = −0,1451 teórico. A de Kelly perde bem menos e tem variabilidade sete vezes menor entre temporadas (desvio de 0,0049 contra 0,0352). Mesmo sendo a melhor das três, ela perde capital nesse mundo: 2^(−0,0456 × 200) ≈ 0,0018, ou seja, o patrimônio típico após 200 rodadas é cerca de 0,2% do inicial (Figura 3.1).

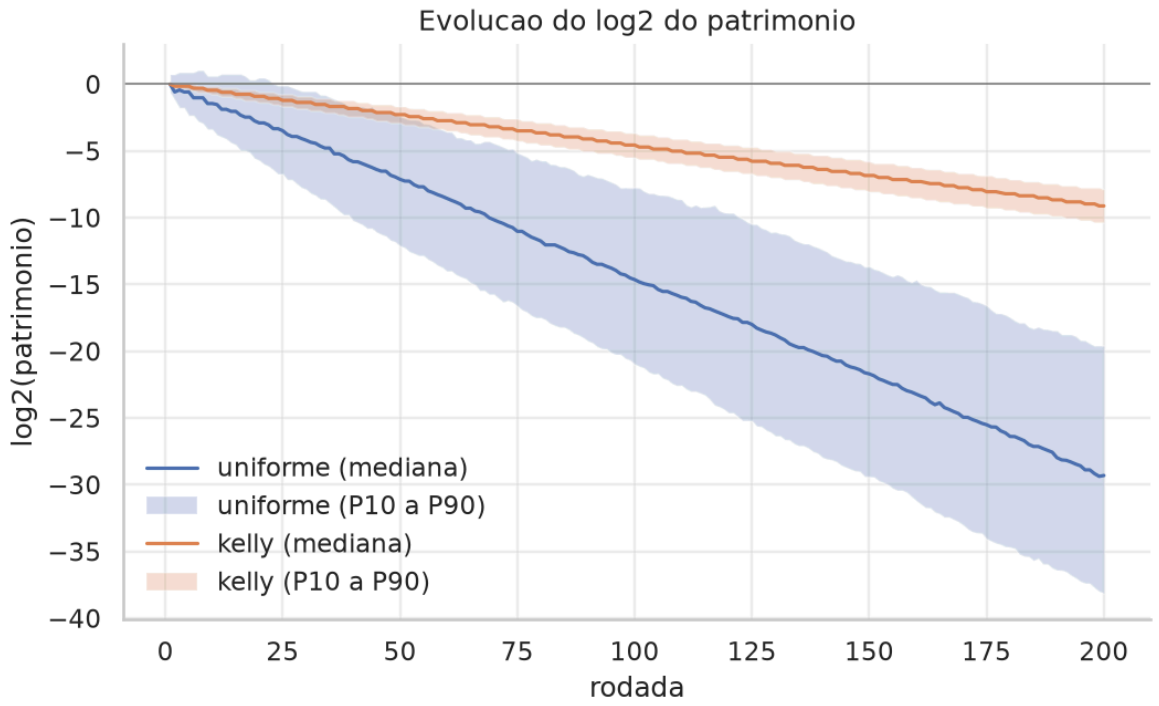


Figura 3.1. Evolução do $\log_2$ do patrimônio (mediana e faixa entre os percentis 10 e 90) das estratégias uniforme e Kelly.

A AEP em ação. Para Kelly, $p_i o_i = (1; 0{,}9; 1)$, então os ganhos por rodada são $(0; -0{,}152; 0)$ e o log-patrimônio é $-0{,}152$ vezes o número de empates. A taxa tem média $W^* = -0{,}0456$ e desvio-padrão por rodada $\sigma = 0{,}0697$; pelo Teorema Central do Limite, o desvio de $(1/n)\log_2 S_n$ deve ser $\sigma/\sqrt{n}$. A Tabela 3.3 confirma a previsão, e a Figura 3.2 mostra a concentração em torno de W^*.

Tabela 3.3. Concentração da taxa de Kelly em torno de $W^* = -0{,}0456$ (1000 temporadas por valor de n).

n (rodadas)	média de $(1/n)\log_2 S$	desvio empírico	$\sigma/\sqrt{n}$ teórico	temporadas em $W^* \pm 0{,}02$
10	−0,0459	0,0218	0,0220	70,8%
100	−0,0456	0,0072	0,0070	99,7%
1000	−0,0455	0,0022	0,0022	100,0%

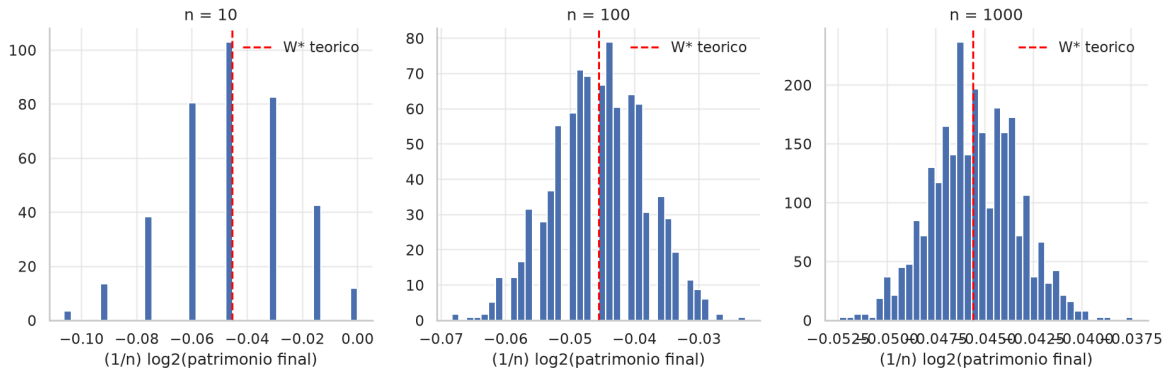


Figura 3.2. Histogramas de (1/n) $\log_2$(patrimônio final) para n = 10, 100 e 1000 (Kelly). A linha tracejada indica W*.

Para n = 10 o histograma é discreto, em "pente", porque o log-patrimônio só assume múltiplos de −0,152; a forma de sino só aparece com n maior. A média empírica é praticamente W* para qualquer n, e o que muda é a dispersão. Essa é a essência da AEP: para n grande o resultado deixa de ser aleatório na escala relevante, e o patrimônio cresce (ou decai) a uma taxa exponencial determinística.

Valor da informação lateral. Com a dica da Tabela 3.1, a marginal de Y é (0,415; 0,350; 0,235) e I(X;Y) = 0,3835 bit (H(X|Y) = 1,1020 contra H(X) = 1,4855). A taxa de crescimento passou de −0,0458 (sem dica) para +0,3396 bit por aposta (com dica), um ganho pareado de ΔW = 0,3855 bit, com erro-padrão de 0,0023 sobre as 1000 temporadas. O valor teórico, 0,3835, fica a 0,85 erro-padrão do estimado, e o valor absoluto previsto com dica, W* + I = 0,3379, também concorda com o simulado. Uma dica que reduz a incerteza em 0,38 bit por rodada transforma um jogo perdedor em um jogo em que o patrimônio é multiplicado, em média geométrica, por 2^0,34 ≈ 1,27 a cada rodada.

Custo de uma crença errada. O apostador com q = (0,7; 0,2; 0,1) cresceu a −0,1784 bit por aposta, contra −0,0457 do apostador de Kelly nas mesmas temporadas. Como na informação lateral, a comparação é pareada: por rodada, a diferença entre os dois é $\log_2(p_x/q_x)$, e a cotação sai da conta. A perda empírica, 0,1327 bit (erro-padrão de 0,0014), fica a 0,04 erro-padrão de D(p‖q) = 0,1328 bit. O custo da crença errada é 2,8 vezes a margem de 0,047 bit da casa: errar sobre o mundo sai mais caro do que a taxa que o mercado cobra.

Cotações uniformes. Como a margem da casa torna W* negativo, o cenário principal não mostra crescimento exponencial. As mesmas 1000 temporadas foram reapostadas contra uma casa que paga $o_i = 3$ para todos os resultados, ignorando que eles não são igualmente prováveis; nenhum sorteio novo foi feito.

Tabela 3.4. Mesmas temporadas, com cotações uniformes $o_i = 3$.

estratégia	W teórico	taxa média (bits/aposta)	temporadas com $\log_2 S > 20$	patrimônio mediano
tudo no favorito	−∞	−∞	0,0%	0
uniforme	0,0000	0,0000	0,0%	1
Kelly	0,0995	0,0997	51,2%	≈ $1{,}2\cdot10^6$

Com cotações uniformes, W* = $\log_2$ m − H(p) = 1,5850 − 1,4855 = 0,0995 bit por aposta, e a simulação de Kelly (0,0997) reproduz esse valor. A estratégia uniforme fica exatamente parada, porque $b_i o_i = 1$ em todos os resultados. O ganho do apostador bem informado é exatamente o quanto a entropia da distribuição real fica abaixo do máximo $\log_2$ m: quanto mais previsível o resultado, mais há a extrair de uma casa que não percebe o padrão. Em metade das temporadas o patrimônio de Kelly passa de $2^{20} \approx 10^6$ vezes o inicial.

3.5 Discussão

A AEP como fio condutor. Compressão e apostas são manifestações do mesmo fenômeno. Na compressão, a AEP garante que as sequências típicas têm probabilidade próxima de 2^(−nH) e que existem cerca de 2^(nH) delas; nas apostas, garante que (1/n) $\log_2 S_n$ converge para W. Nos dois casos o comportamento médio só é relevante porque o desvio em torno dele é de ordem 1/√n, como na Tabela 3.3.

Kelly maximiza crescimento, não valor esperado. O fator esperado por rodada de Kelly é 0,970, menor que o de "tudo no favorito" (1,000), e ainda assim a primeira é incomparavelmente melhor no longo prazo. A distinção entre o valor esperado de S_n e seu valor típico, medido por E[log S_n], é a principal lição prática do critério.

Informação é crescimento. A igualdade ΔW = I(X;Y) dá à informação mútua uma leitura operacional: bits de informação sobre o resultado convertem-se, um a um, em bits de taxa de dobra. Do mesmo modo, D(p‖q) é o preço, em bits por rodada, de operar com o modelo errado.

Limitações. (i) As cotações principais contêm margem de 3,3%, de modo que W* é negativo; o crescimento positivo de Kelly sem a dica aparece apenas no cenário de cotações uniformes. (ii) Com um ativo sem risco (opção de não apostar), a decisão ótima nesse mundo seria abster-se, alternativa que o modelo não contempla. (iii) O apostador conhece p exatamente; na prática p seria estimado, e o erro de estimação gera justamente o tipo de perda medido por D(p‖q). (iv) Assumiram-se rodadas i.i.d., ausência de custos de transação e frações de aposta arbitrariamente divisíveis. (v) A compressão foi tratada analiticamente (entropia e comprimentos do código de Huffman, calculados no notebook); nenhuma sequência foi de fato codificada.

3.6 Conclusão

A simulação reproduziu todas as previsões teóricas do tópico: a taxa de crescimento empírica coincidiu com W(b,p) para as três estratégias, o desvio caiu como σ/√n, o ganho da informação lateral igualou I(X;Y) (0,3855 contra 0,3835 bit), a perda por crenças erradas igualou D(p‖q) (0,1327 contra 0,1328 bit) e, com cotações uniformes, a taxa de Kelly reproduziu W* = $\log_2$ m − H(p) (0,0997 contra 0,0995 bit). A Lei dos Grandes Números e o Teorema Central do Limite, aplicados a variáveis logarítmicas, fornecem tanto o limite de compressão quanto o critério ótimo de alocação de capital, e entropia, divergência de Kullback-Leibler e informação mútua ganham interpretações diretas em bits por observação.

---

4. Capacidade de canal e códigos corretores de erro

4.1 Objetivo

Testar na prática os limites do teorema da codificação de canal de Shannon num link de rádio Terra-Marte modelado como canal binário simétrico (BSC): (i) a taxa de erro de bit (BER) sem codificação coincide com o parâmetro p? (ii) como se comparam repetição e Hamming(7,4) em taxa efetiva R = k/n e BER? (iii) aumentando o bloco de repetição, a taxa de erro cai como prevê a cauda binomial? (iv) o que acontece quando R > C?

4.2 Fundamentação

O BSC com parâmetro p entrega o bit enviado com probabilidade 1 − p e o inverte com probabilidade p, de forma independente a cada uso. Sua capacidade, C = max I(X;Y), é atingida com entrada uniforme e vale C = 1 − H_b(p), com H_b(p) = −p $\log_2$ p − (1 − p) $\log_2$(1 − p).

Pelo teorema da codificação de canal, para qualquer taxa R < C existem códigos de bloco suficientemente longos com probabilidade de erro arbitrariamente pequena; para R > C, nenhum código consegue isso. Combinada com a teoria de taxa-distorção, a parte inversa dá um piso concreto: nenhum código de taxa R > C tem BER menor que $H_b^{-1}(1 - C/R)$ (MacKay, 2003, cap. 10).

O código de repetição envia cada bit nr vezes (nr ímpar) e decodifica por maioria; tem taxa R = 1/nr e erra exatamente quando mais da metade das cópias é invertida, com probabilidade P(Bin(nr, p) > nr/2). O Hamming(7,4) transforma 4 bits de informação em 7 (R = 4/7) e corrige, por síndrome, qualquer erro único dentro do bloco.

4.3 Modelo e método

- **Mensagem.** Uma fotografia real (2570 × 3427 pixels), em escala de cinza e binarizada pela média de cinza, o que dá N = 8.807.388 bits com fração de 1s de 0,5204, próxima da entrada uniforme que atinge a capacidade.
- **Canal principal.** p = 0,10, com semente fixa.
- **Esquemas comparados.** Sem codificação (R = 1), repetição com nr = 3 (R = 1/3) e Hamming(7,4) (R = 4/7), implementados como operações vetorizadas sobre vetores de bits (inversão por XOR, voto de maioria, síndrome), sem bibliotecas de códigos corretores. O SciPy entra só como conferência da cauda binomial.
- **Varreduras.** p ∈ {0,02; 0,05; 0,10; 0,15; 0,20; 0,30} para os três esquemas; nr de 3 a 15 com p = 0,10.
- **Cenário R > C.** Canal com p = 0,40 (C = 0,0290 bit), reconstrução visual da imagem recebida e varredura de nr nesse mesmo canal, para tentar de fato reduzir a BER.
- **Piso teórico.** Para todo esquema com R > C, a BER medida é comparada com $H_b^{-1}(1 - C/R)$. A BER exata do Hamming(7,4) é calculada enumerando os 128 padrões de erro de um bloco.

4.4 Resultados

Capacidade e transmissão direta. Para p = 0,10, H_b(p) = 0,4690 bit e C = 0,5310 bit por uso do canal. Transmitindo os 8.807.388 bits sem proteção, a BER foi 0,1001, contra p = 0,1000: com quase 9 milhões de bits, a fração observada de inversões converge para a probabilidade de erro do canal.

Comparação dos esquemas (p = 0,10).

Tabela 4.1. Taxa efetiva, BER pós-decodificação e piso teórico (p = 0,10).

esquema	R = k/n	BER	R > C	piso teórico da BER
sem codificação	1,0000	0,100093	sim	0,1000
repetição (nr = 3)	0,3333	0,028023	não	0
Hamming(7,4)	0,5714	0,066832	sim	0,0085

A repetição com nr = 3 é a que mais reduz erros (BER 3,6 vezes menor que sem codificação), ao custo de três bits transmitidos por bit de informação. O Hamming(7,4) preserva mais taxa e leva a BER a cerca de dois terços do valor sem codificação.

A BER sozinha esconde um ponto: com C = 0,5310, o Hamming(7,4) (R = 0,5714) já opera acima da capacidade, assim como a transmissão direta. Para R = 4/7 o piso é 0,0085: nenhum código dessa taxa nesse canal, por mais sofisticado, chegaria abaixo de 0,85% de bits errados, e o Hamming(7,4) fica em 6,7%. Para a transmissão direta o piso é exatamente p, e a BER medida está em cima dele. Só a repetição, com R = 1/3 < C, está numa taxa em que a BER pode, em princípio, ser levada a zero.

Efeito da intensidade do ruído.

Tabela 4.2. BER pós-decodificação para diferentes valores de p.

p	sem codificação	repetição (nr = 3)	Hamming(7,4)	Hamming(7,4) exato
0,02	0,019980	0,001164	0,003342	0,003397
0,05	0,050074	0,007234	0,019431	0,019434
0,10	0,099874	0,027964	0,067010	0,066880
0,15	0,149775	0,060816	0,129248	0,129026
0,20	0,199982	0,104136	0,196014	0,196160
0,30	0,299838	0,216050	0,322186	0,321840

A linha p = 0,10 vem de uma nova realização do canal, por isso difere levemente da Tabela 4.1.

A vantagem dos códigos diminui conforme o canal fica mais ruidoso. Até p = 0,20 o Hamming(7,4) tem BER menor que a transmissão direta, mas a vantagem encolhe rápido (0,196 contra 0,200 em p = 0,20), e em p = 0,30 ele fica pior que não codificar (0,322 contra 0,300). O motivo é que o código corrige apenas um erro por bloco: num bloco com exatamente 2 erros, o decodificador sempre "corrige" uma terceira posição. Como o Hamming(7,4) é um código perfeito, toda síndrome não nula aponta para exatamente um bit, e a soma de duas colunas da matriz de verificação é sempre uma terceira coluna; o bloco sai com 3 erros. A BER exata confere com a simulação em todas as linhas e situa o cruzamento com a transmissão direta em p = 0,2113, cerca de 1,5 erro esperado por bloco de 7 bits (Figura 4.1). A repetição mantém a vantagem em toda a faixa testada, porque a decisão por maioria degrada de forma mais suave.

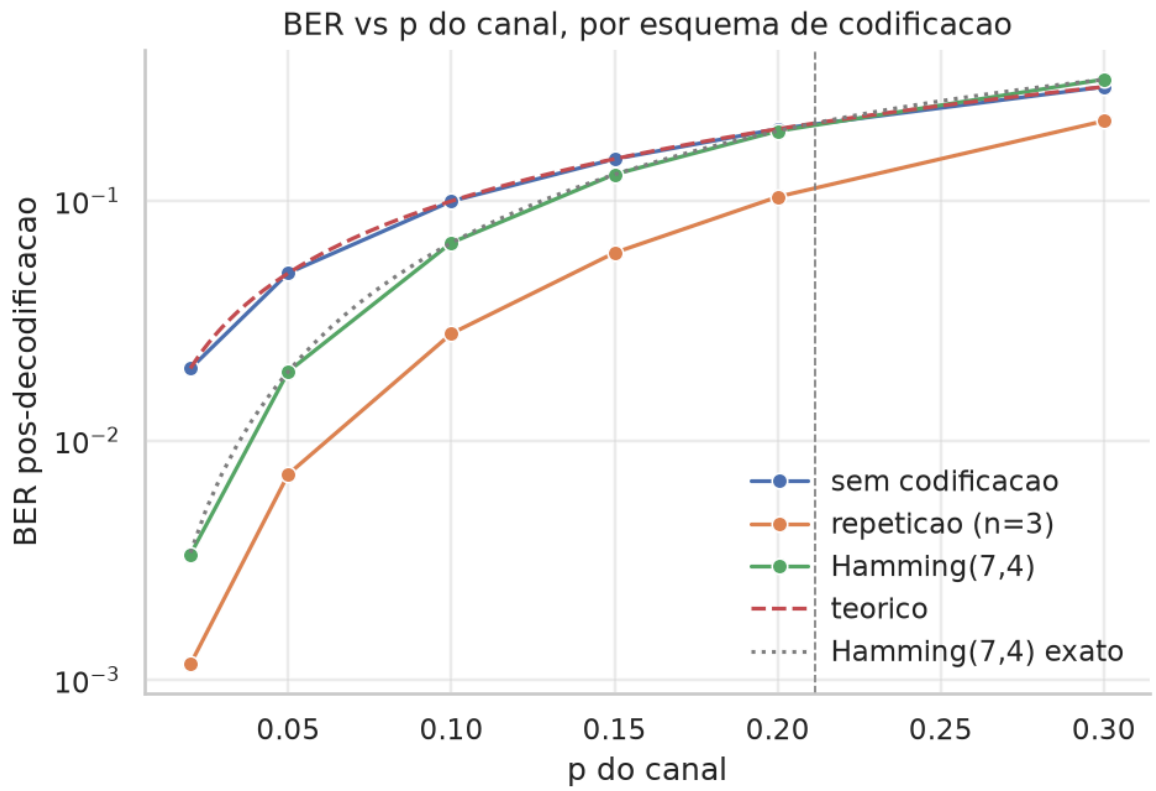


Figura 4.1. BER pós-decodificação contra p, em escala logarítmica, com a curva exata do Hamming(7,4) e o cruzamento em p = 0,2113.

Repetição, comprimento de bloco e a promessa de Shannon.

Tabela 4.3. Taxa de erro de bloco da repetição, p = 0,10 (C = 0,5310 bit).

nr	R = 1/nr	C − R	BER empírica	BER teórica (binomial)
3	0,3333	0,1977	0,027955	0,028000
5	0,2000	0,3310	0,008569	0,008560
7	0,1429	0,3881	0,002748	0,002728
9	0,1111	0,4199	0,000886	0,000891
11	0,0909	0,4401	0,000285	0,000296
13	0,0769	0,4541	0,000107	0,000099
15	0,0667	0,4643	0,000032	0,000034

A taxa de erro cai de forma aproximadamente exponencial com nr (cerca de uma ordem de grandeza a cada aumento de 4) e coincide com a cauda binomial em todas as linhas (Figura 4.2). Isso ilustra a parte direta do teorema: aumentando o bloco, a taxa de erro pode ser tão pequena quanto se queira, desde que R fique abaixo de C. A queda da BER sozinha, porém, não distingue os dois regimes: no cenário R > C abaixo, a BER da repetição também cai com nr. O que muda é se ela pode chegar a zero.

A repetição ilustra o teorema de forma pouco eficiente: para levar a BER a quase zero, ela leva R a quase zero também, enquanto o teorema garante códigos que mantêm R arbitrariamente perto de C com probabilidade de erro tendendo a zero.

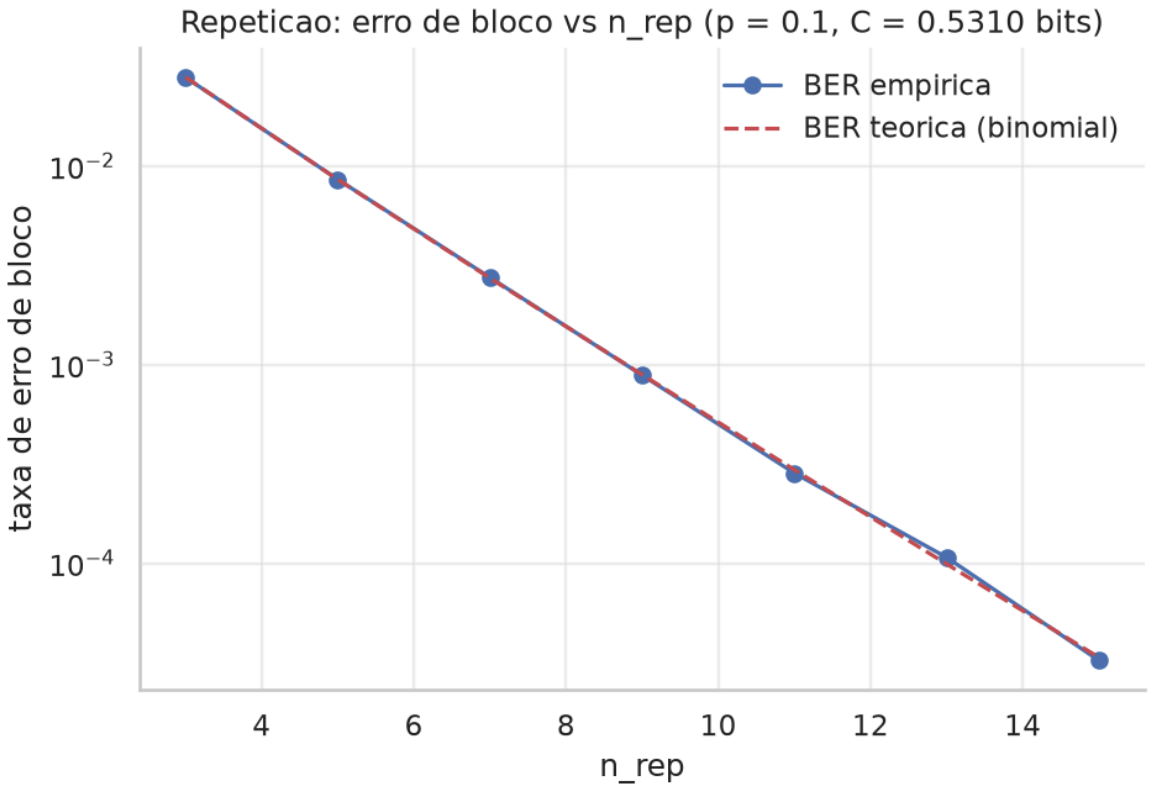


Figura 4.2. Taxa de erro de bloco da repetição contra nr (p = 0,10), empírica e pela cauda binomial.

Cenário R > C.

Tabela 4.4. Os três esquemas num canal muito ruidoso (p = 0,40, C = 0,0290 bit).

esquema	R	BER	R > C	BER aceitável (< 0,01)	piso teórico da BER
sem codificação	1,0000	0,400243	sim	não	0,4000
repetição (nr = 3)	0,3333	0,352111	sim	não	0,3280
Hamming(7,4)	0,5714	0,420998	sim	não	0,3681

Com C = 0,0290 bit, bem abaixo da taxa de qualquer um dos três esquemas, nenhum chega perto de uma BER aceitável: mesmo a repetição erra 35% dos bits. O Hamming(7,4) volta a ser o pior, acima até da transmissão direta, pelo mesmo mecanismo de correção errada, agora amplificado pelo p alto. As três BERs ficam acima do piso teórico de suas taxas, como o teorema exige. A reconstrução visual confirma: as imagens da varredura de nr com p = 0,10 (R < C) ficam cada vez mais nítidas, enquanto as três do canal com p = 0,40 permanecem irreconhecíveis (Figura 4.3).

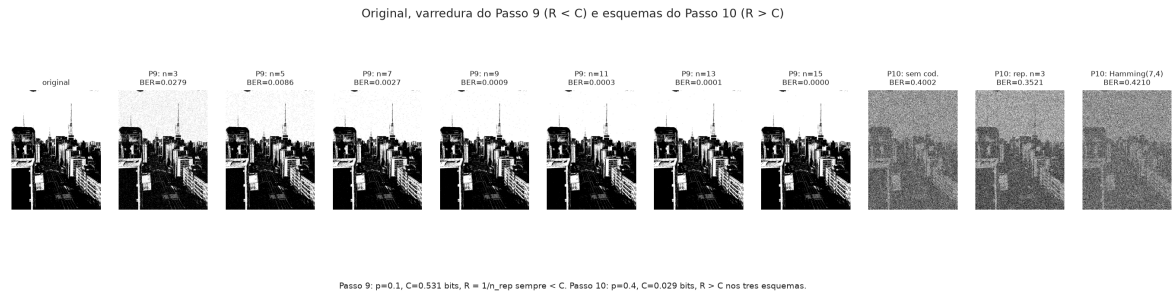


Figura 4.3. Imagem original, imagens recebidas na varredura de nr com p = 0,10 (R < C) e nos três esquemas com p = 0,40 (R > C).

O roteiro pede para tentar reduzir a taxa de erro a um nível aceitável com os códigos disponíveis, e a repetição permite isso aumentando nr. A Tabela 4.5 mostra o resultado no canal com p = 0,40, sobre os primeiros 100.000 bits da imagem (com BER da ordem de 1%, ainda são cerca de mil erros por ponto).

Tabela 4.5. Repetição no canal com p = 0,40 (C = 0,0290 bit), para nr crescente.

nr	R = 1/nr	R > C	BER empírica	BER teórica (binomial)	piso teórico
3	0,3333	sim	0,3515	0,3520	0,3280
9	0,1111	sim	0,2677	0,2666	0,2085
19	0,0526	sim	0,1854	0,1861	0,0935
33	0,0303	sim	0,1223	0,1211	0,0045
35	0,0286	não	0,1137	0,1143	0
51	0,0196	não	0,0730	0,0735	0
75	0,0133	não	0,0399	0,0396	0
101	0,0099	não	0,0206	0,0209	0
133	0,0075	não	0,0097	0,0098	0
151	0,0066	não	0,0065	0,0064	0

A BER cai com nr mesmo enquanto R está acima de C: com nr = 33, o último valor ímpar com R > C, ela já é 0,122, contra 0,352 com nr = 3. O teorema não proíbe essa queda; proíbe que, acima de C, a BER desça abaixo do piso, e por isso ela não pode ser levada a zero sem abrir mão da taxa. Uma BER abaixo de 1% só aparece com nr = 133, quando R = 0,0075 é cerca de um quarto da capacidade (Figura 4.4). Para comunicar de forma confiável nesse canal é preciso descer abaixo de C e, com a repetição, bem abaixo. A coluna do piso mostra também o quanto a repetição está longe do melhor código possível: com nr = 33, um código ótimo da mesma taxa poderia ter BER de 0,0045, e a repetição tem 0,122.

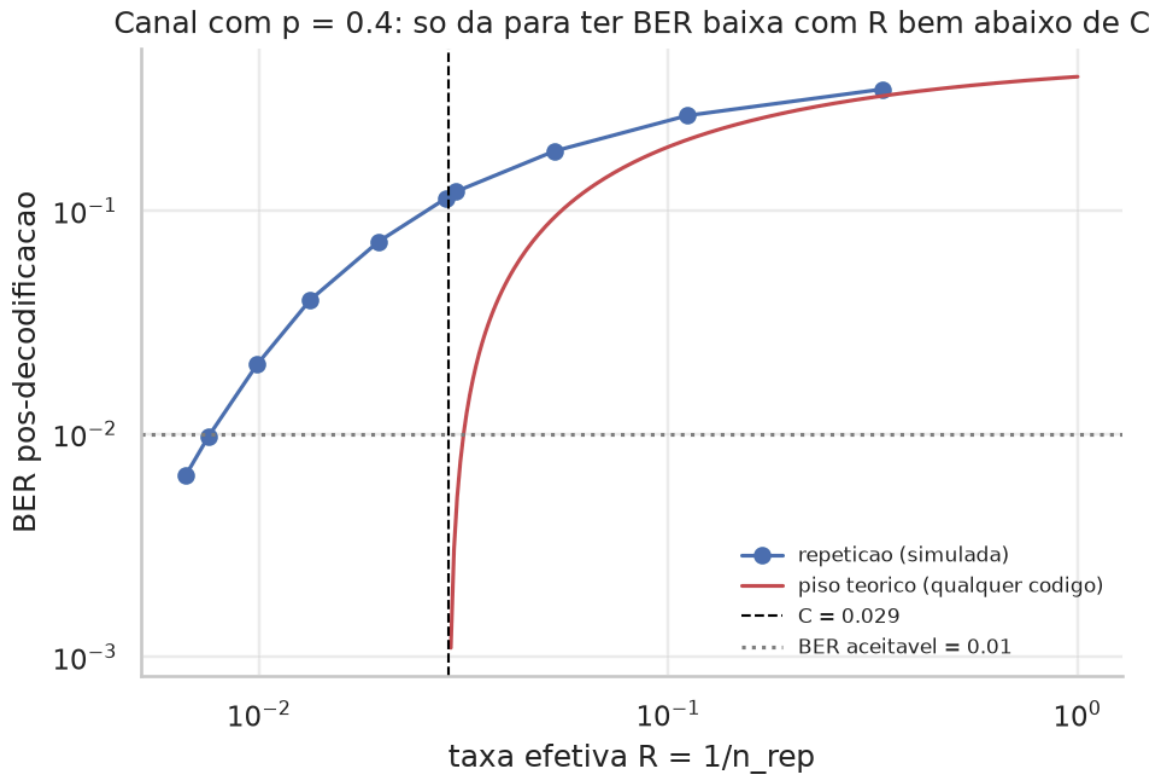


Figura 4.4. BER da repetição contra R no canal com p = 0,40, com o piso teórico, a capacidade C e o limiar de BER aceitável.

4.5 Discussão

A capacidade como fronteira real. As Tabelas 4.3 e 4.5 mostram os dois lados do teorema com o mesmo código: quando R < C, aumentar o bloco reduz a BER de forma sistemática e previsível; quando R > C, aumentar a redundância ainda reduz a BER, mas ela nunca desce abaixo do piso teórico e só fica aceitável depois que R cai bem abaixo de C.

Redundância não é sinônimo de robustez. O Hamming(7,4) é mais eficiente que a repetição em taxa (4/7 contra 1/3), mas piora à medida que o canal fica mais ruidoso, chegando a perder para a ausência de codificação em p = 0,30 e p = 0,40. Isso decorre de ele corrigir um único bit por bloco: quando o número esperado de erros por bloco (7p) passa de cerca de 1,5, a decodificação por síndrome introduz mais erros do que remove.

Repetição como demonstração, não como código ótimo. A repetição reduz a taxa de erro arbitrariamente às custas de $R \to 0$. Testar um código que se aproxime de C com erro baixo (por exemplo, um código de blocos aleatório com decodificação por máxima verossimilhança) seria a extensão natural.

Limitações. (i) Só dois códigos simples foram testados; um código moderno (Reed-Solomon, LDPC) permitiria observar taxas mais próximas de C com BER baixa. (ii) O canal foi sempre o BSC; ruído em rajadas, mais realista num enlace real, exigiria entrelaçamento antes da codificação. (iii) C foi calculada analiticamente, sem estimar I(X;Y) a partir das amostras como conferência. (iv) O critério de BER aceitável (< 0,01) é arbitrário; a referência não arbitrária é o piso $H_b^{-1}(1 - C/R)$, que vale para qualquer código e aparece nas Tabelas 4.1, 4.4 e 4.5.

4.6 Conclusão

A simulação reproduziu as previsões centrais do teorema da codificação de canal. A BER sem codificação coincidiu com p. Taxa efetiva mais alta não implica maior robustez: o Hamming(7,4) perde vantagem e acaba pior que não codificar quando o canal fica ruidoso. A varredura do bloco de repetição confirmou, contra a cauda binomial, que a taxa de erro pode ser reduzida arbitrariamente quando R < C, ainda que a repetição pague com uma taxa que tende a zero. No cenário R > C, nenhum esquema produziu comunicação confiável, todas as BERs ficaram acima do piso teórico $H_b^{-1}(1 - C/R)$, e a repetição só alcançou BER aceitável quando R desceu a cerca de um quarto de C. O piso também mostrou que o Hamming(7,4) já opera acima da capacidade no canal principal.

Conclusão geral

As quatro simulações confirmaram, com dados gerados e estimativas feitas a partir das definições, as previsões teóricas de cada tópico, e mostraram que as mesmas poucas quantidades têm leituras operacionais diferentes conforme o problema:

- a **entropia** é o custo mínimo de descrição: dos testes de dengue ao longo dos dias (Tópico 1), dos resultados de futebol (Tópico 3) e do ruído que o canal adiciona (Tópico 4);
- a **informação mútua** é o quanto uma observação diz sobre outra: o teste sobre a doença (Tópico 1), cada elo da cadeia sobre a entrada (Tópico 2), a dica sobre o resultado, convertida um a um em taxa de crescimento (Tópico 3), e o canal sobre o bit enviado, cujo máximo é a capacidade (Tópico 4);
- a **divergência de Kullback-Leibler** é o preço de usar o modelo errado: bits a mais na codificação (Tópico 1), afastamento acumulado no colapso de modelo (Tópico 2) e taxa de crescimento perdida por crenças erradas (Tópico 3).

Em todos os tópicos, a comparação com a teoria só foi conclusiva porque a incerteza da estimativa foi medida (IC bootstrap, várias réplicas, erro de Monte Carlo ou conferência exata), e vários dos resultados mais interessantes apareceram justamente onde a estimativa ingênua falharia: as amostras sem infectados em N pequeno, a pseudorreplicação no teste G, a divergência infinita após a extinção de uma categoria e o Hamming(7,4) já operando acima da capacidade.

Referências

COVER, T. M.; THOMAS, J. A. *Elements of Information Theory*. 2. ed. Hoboken: Wiley-Interscience, 2006.

HAMMING, R. W. Error detecting and error correcting codes. *Bell System Technical Journal*, v. 29, n. 2, p. 147-160, 1950.

KELLY, J. L. A new interpretation of information rate. *Bell System Technical Journal*, v. 35, n. 4, p. 917-926, 1956.

MACKAY, D. J. C. *Information Theory, Inference, and Learning Algorithms*. Cambridge: Cambridge University Press, 2003.

SHANNON, C. E. A mathematical theory of communication. *Bell System Technical Journal*, v. 27, n. 3, p. 379-423, 1948.